

**APLIKASI KATEGORISASI GAMBAR OTOMATIS UNTUK
PENYORTIRAN DOKUMENTASI FOTO ACARA CALVIN
INSTITUTE OF TECHNOLOGY MENGGUNAKAN CNN
TUGAS AKHIR**

Disusun oleh:
Dominique (202000216)

Sebagai salah satu syarat untuk memperoleh gelar
Sarjana Komputer (S.Kom.)
dari Calvin Institute of Technology



**PROGRAM STUDI IT & BIG DATA ANALYTICS
FAKULTAS SAINS DAN TEKNIK
CALVIN INSTITUTE OF TECHNOLOGY
2024**

HALAMAN PENGESAHAN
TUGAS SARJANA KOMPUTER

APLIKASI KATEGORISASI GAMBAR OTOMATIS UNTUK
PENYORTIRAN DOKUMENTASI FOTO ACARA CALVIN
INSTITUTE OF TECHNOLOGY MENGGUNAKAN CNN

Disusun oleh:

Dominique (202000216)

Program Studi Sarjana Komputer

Fakultas Sains dan Teknik

Calvin Institute of Technology

Menyetujui,

Dosen Pembimbing

Steven Bandong, S.Si., M.T.

NIP: 20240101001

Mengetahui,

Dosen Penguji 1

Dosen Penguji 2

Ketua Program Studi
IT & Big Data Analytics

Hendirk Santoso Sugiarto,

B.Sc., Ph.D.

NIP: 20220101001

Bambang Lareno, S.T.,

M.Kom.

NIP: 20200101001

Hendirk Santoso Sugiarto,

B.Sc., Ph.D.

NIP: 20220101001

HALAMAN PERNYATAAN KEASLIAN

Tugas Akhir ini adalah hasil karya saya sendiri, dan ditulis dengan mengikuti kaidah penulisan ilmiah. Apabila di kemudian hari ditemukan bahwa karya tulis ini menyalahi peraturan yang ada berkaitan etika dan kaidah penulisan karya ilmiah yang berlaku, maka saya bersedia menerima sanksi akademik dan/atau hukum sesuai dengan ketentuan yang berlaku.

Nama (NIM) : Dominique (202000216)

Program Studi : IT and Big Data Analytics

Fakultas : Sains dan Teknik

Tanda Tangan :

(Dominique)

Tanggal : 20 Juni 2024

Mengetahui

Pembimbing 1 : Steven Bandong, S.Si., M.T. ()

ABSTRAK

APLIKASI KATEGORISASI GAMBAR OTOMATIS UNTUK PENYORTIRAN DOKUMENTASI FOTO ACARA CALVIN INSTITUTE OF TECHNOLOGY MENGGUNAKAN CNN

Dominique (202000216)

Program Studi IT and Big Data Analytics, Fakultas Sains dan Teknik

Calvin Institute of Technology

Dalam setiap acara yang diselenggarakan oleh Calvin Institute of Technology (CIT), dokumentasi fotografi memegang peranan yang sangat penting. Oleh karena itu, tugas menyortir dan mengkategorikan foto yang diperoleh juga tentunya merupakan hal yang perlu untuk dilakukan. Proyek ini bertujuan untuk mengotomatisasi proses kategorisasi dokumentasi fotografi dalam acara-acara yang diselenggarakan oleh CIT melalui penerapan teknologi kecerdasan buatan, khususnya *convolutional neural network* (CNN). Proses penyortiran dan kategorisasi manual yang masih dilakukan pada saat ini, yang cukup memakan waktu dan tenaga, akan disederhanakan. Sistem yang diusulkan ini bertujuan untuk secara otomatis mengelompokkan foto-foto acara ke dalam kelompok-kelompok tertentu berdasarkan fitur atau karakteristik yang teridentifikasi dalam gambar, dengan memastikan kategorisasi yang efisien dan akurat. Keberhasilan proyek ini diharapkan dapat meningkatkan efisiensi proses penyortiran dan kategorisasi untuk dokumentasi fotografi acara di departemen media kreatif CIT.

Kata kunci: kategorisasi gambar otomatis, *Convolutional Neural Network*.

ABSTRACT

AUTOMATIC IMAGE CATEGORIZATION APPLICATION FOR PHOTO DOCUMENTATION SORTING OF CALVIN INSTITUTE OF TECHNOLOGY EVENTS USING CNN

Dominique (202000216)

IT and Big Data Analytics Program of Study, Faculty of Science and Engineering

Calvin Institute of Technology

In every event organized by Calvin Institute of Technology (CIT), photographic documentation is of paramount importance. Therefore, the task of sorting and categorizing the acquired photographs is also essential. This project endeavors to automate the categorization of photographic documentation in events organized by CIT through the implementation of artificial intelligence technology, specifically convolutional neural networks (CNN). The current manual sorting and categorization process, which proves labor-intensive and time-consuming, will be streamlined. The proposed system aims to automatically classify event photos into distinct groups based on identified features or characteristics within the images, while ensuring efficient and accurate categorization. The success of this project is anticipated to enhance the efficiency of the sorting and categorization process for event photo documentation within CIT's creative media department.

Keywords: automatic image categorization, Convolutional Neural Network.

PEDOMAN PENGGUNAAN TUGAS AKHIR

Tugas Akhir yang tidak dipublikasikan terdaftar dan tersedia di Perpustakaan Calvin Institute of Technology secara *online*. Tugas Akhir ini terbuka untuk umum dengan ketentuan bahwa hak cipta ada pada penulis dengan mengikuti aturan HaKI yang berlaku di Calvin Institute of Technology. Referensi kepustakaan diperkenankan dicatat sesuai dengan kaidah ilmiah, sedangkan untuk pengutipan atau peringkasan hanya dapat dilakukan seizin penulis.

Menerbitkan sebagian atau seluruh Tugas Akhir maupun memperbanyak haruslah seizin Wakil Rektor 1 Bidang Akademik, Calvin Institute of Technology.

DAFTAR ISI

ABSTRAK	iii
ABSTRACT	iv
PEDOMAN PENGGUNAAN TUGAS AKHIR	v
DAFTAR ISI	vi
DAFTAR GAMBAR	viii
BAB I	1
PENDAHULUAN	1
1.1. Latar Belakang	1
1.2. Rumusan Masalah	2
1.3. Tujuan Penelitian	2
BAB II	3
TINJAUAN PUSTAKA	3
2.1. Metodologi	3
2.1.1. Studi Literatur	4
2.1.2. Perancangan Arsitektur	4
2.1.3. Pengumpulan Dataset	4
2.1.4. Pemilihan Model	4
2.1.5. Penelitian Model	4
2.1.6. Analisis	4
2.1.7. Pengujian	5
2.2. Glosarium	5
2.2.1. <i>Artificial Intelligence</i>	5
2.2.2. <i>Computer Vision</i>	5
2.2.3. <i>Convolutional Neural Network</i>	5
BAB III	8
DESAIN	8
3.1. Aplikasi Kategorisasi Gambar Otomatis	8
3.1.1. <i>Overview Desain</i>	9
3.1.2. <i>User Interface (UI)</i>	9
3.2. Sistem AI	10
3.2.1. Model	10
3.2.2. Dataset	11
3.2.3. Kelompok Klasifikasi Model	11

3.2.4. Pengembangan Model	12
BAB IV	14
HASIL DAN PEMBAHASAN	14
4.1. <i>Data Preprocessing</i> (Pra-pemrosesan Data)	14
4.2. Proses Pelatihan Model	15
4.2.1. Pemuatan Dataset	15
4.2.2. Setup Model	15
4.2.3. Pelatihan Awal	16
4.2.4. Hasil Pelatihan Awal	18
4.2.5. <i>Fine-Tuning Model</i>	20
4.2.6. Hasil <i>Fine-Tuning</i>	21
4.3. Pengujian Model dengan Data Uji dan Analisis Performa	23
4.3.1. Perbandingan Kinerja Model	27
4.4. Aplikasi	27
BAB V	30
KESIMPULAN DAN SARAN	30
5.1. Kesimpulan	30
5.2. Saran	30
DAFTAR PUSTAKA	32

DAFTAR GAMBAR

Gambar 2.1 Alur Metodologi Pengembangan Aplikasi	3
Gambar 2.2 Arsitektur CNN	6
Gambar 3.1 Activity Diagram Aplikasi	7
Gambar 3.2 Desain UI: Home	9
Gambar 3.3 Desain UI: setelah mengunggah file	9
Gambar 4.1 Data Perwakilan dari Masing-Masing Kategori	14
Gambar 4.2 Blok Kode untuk Memuat Dataset	15
Gambar 4.3 Blok Kode untuk <i>Setup</i> Model	15
Gambar 4.4 Blok Kode untuk Memperkirakan <i>Learning Rate</i> Optimal	16
Gambar 4.5 Grafik <i>Loss</i> sebagai Fungsi dari <i>Learning Rate</i>	16
Gambar 4.6 Blok Kode untuk Melatih Model	17
Gambar 4.7 Grafik <i>Accuracy</i> per <i>Epoch</i>	18
Gambar 4.8 Grafik <i>Train Loss</i> per <i>Epoch</i>	19
Gambar 4.9 Grafik <i>Train Loss</i> dan <i>Validation Loss</i> per <i>Epoch</i>	19
Gambar 4.10 Blok Kode untuk <i>Fine-Tuning</i> Model dengan <i>Unfreezing</i> Lapisan yang Dibekukan	20
Gambar 4.11 Grafik Perbandingan <i>Accuracy</i> per <i>Epoch</i> sebelum dan setelah <i>Fine-Tuning</i>	21
Gambar 4.12 Grafik <i>Train Loss</i> dan <i>Validation Loss</i> per <i>Epoch</i> setelah <i>Fine-Tuning</i>	21
Gambar 4.13 Grafik Perbandingan <i>Train Loss</i> per <i>Epoch</i> sebelum dan setelah <i>Fine-Tuning</i>	22
Gambar 4.14 Grafik Perbandingan <i>Validation Loss</i> per <i>Epoch</i> sebelum dan setelah <i>Fine-Tuning</i>	22
Gambar 4.15 Blok Kode untuk Menguji Model dengan Data Uji	23
Gambar 4.16 Performa Model setelah Pengujian	23
Gambar 4.17 <i>Confusion Matrix</i> dari Hasil Pengujian Model	24
Gambar 4.18 Lima Prediksi yang Terbaik oleh Model	26
Gambar 4.19 Lima Prediksi yang Terburuk oleh Model	26
Gambar 4.20 Perbandingan Kinerja ResNet dengan VGG dan AlexNet	27
Gambar 4.21 <i>Home Page</i> Aplikasi Web	28
Gambar 4.22 Tampilan <i>Page</i> Setelah Mengunggah dan Memproses File Zip, kemudian File Zip Hasil Pemrosesan Diunduh	29

Gambar 4.23 File Zip Hasil Pengunduhan 29

BAB I

PENDAHULUAN

1.1. Latar Belakang

Dokumentasi fotografi merupakan suatu hal yang esensial karena salah satu fungsinya adalah sebagai rekaman visual dari suatu peristiwa, aktivitas, atau pencapaian tertentu. Berbagai sektor kehidupan, seperti bisnis, jurnalistik, penelitian, dan pendidikan, tidak akan terlepas dari dokumentasi fotografi. Dokumentasi fotografi mempunyai fungsinya tersendiri pada masing-masing sektor yang ada. Secara menyeluruh, dokumentasi fotografi membuka peluang untuk mengungkap, menyampaikan, dan menyimpan informasi dengan tingkat kekuatan dan kedalaman yang melampaui kapasitas kata-kata semata. Kehadiran fotografi memegang peranan yang sangat penting sebagai suatu jendela yang memberikan akses ke masa lalu, menjadi alat komunikasi yang berdaya tinggi, dan merangkum sebagai sumber daya yang berharga dalam upaya membangun pengetahuan serta pengalaman (Ash, 2022).

Ada satu hal yang tidak dapat dilewatkan di dalam proses melakukan dokumentasi fotografi, yaitu proses penyortiran dan pengkategorian foto-foto hasil dokumentasi. Foto-foto hasil dokumentasi yang memiliki “tema” yang sama akan dikelompokkan menjadi satu. Contohnya, apabila acara yang didokumentasikan adalah acara lomba olahraga, maka foto-foto dapat dibagi ke dalam beberapa kelompok berdasarkan bidang olahraga di dalam lomba tersebut. Proses penyortiran dan pengkategorian ini sering kali masih dilakukan secara manual oleh banyak pihak, dan Calvin Institute of Technology (CIT) juga merupakan salah satu yang masih melakukan penyortiran dan pengkategorian dokumentasi fotografi secara manual. Namun, tugas menyortir dan mengkategorikan foto-foto dokumentasi secara manual merupakan suatu hal yang cukup memakan tenaga dan waktu, terlebih lagi apabila foto-foto yang diambil berjumlah ratusan hingga ribuan. Oleh karena itu, diperlukan suatu solusi yang canggih dan efisien untuk dapat mengatasi masalah ini.

Proyek ini bertujuan untuk mengotomatisasi proses kategorisasi dokumentasi foto acara CIT dengan menerapkan teknologi kecerdasan buatan menggunakan *convolutional neural network* (CNN). Foto-foto hasil dokumentasi akan dikategorisasi secara otomatis ke dalam beberapa kelompok tertentu berdasarkan fitur atau ciri-ciri yang terdeteksi di

dalam foto-foto tersebut. Foto-foto yang memiliki fitur yang cukup mirip akan dikategorisasi di dalam satu kelompok yang sama.

Tingkat akurasi yang tinggi dalam mengkategorisasi gambar-gambar adalah hal yang utama untuk meminimalkan kesalahan dalam mendeteksi fitur-fitur dalam gambar sehingga gambar dapat dikategorisasi secara akurat. Proyek ini diharapkan akan meningkatkan efisiensi dan memudahkan proses penyortiran dan pengkategorian dokumentasi foto acara bagi departemen media kreatif di dalam CIT.

1.2. Rumusan Masalah

Dalam memenuhi kebutuhan CIT untuk mengembangkan aplikasi kategorisasi gambar otomatis, beberapa masalah muncul:

- Bagaimana tingkat keakuratan aplikasi kategorisasi gambar dengan menerapkan teknologi kecerdasan buatan menggunakan *convolutional neural network*?
- Apakah model CNN yang digunakan efektif, efisien, dan sesuai untuk aplikasi kategorisasi gambar ini?
- Bagaimana memastikan aplikasi yang dikembangkan dapat disesuaikan dengan kebutuhan spesifik CIT?
- Bagaimana mengintegrasikan model AI yang telah dibangun dengan website aplikasi?

1.3. Tujuan Penelitian

Penelitian ini bertujuan untuk:


- Mengembangkan aplikasi kategorisasi gambar otomatis yang memiliki tingkat keakuratan yang tinggi dengan menerapkan teknologi kecerdasan buatan menggunakan *convolutional neural network*.
- Menggunakan model CNN yang efektif, efisien, dan sesuai untuk aplikasi kategorisasi gambar yang dikembangkan.
- Mengembangkan aplikasi kategorisasi gambar otomatis yang dapat disesuaikan dengan kebutuhan spesifik dari CIT.
- Mengintegrasikan model AI yang telah dibangun dengan website aplikasi.

BAB II

TINJAUAN PUSTAKA

2.1. Metodologi

Untuk membantu proses pengembangan aplikasi kategorisasi gambar otomatis ini, diperlukan suatu pendekatan ataupun langkah-langkah sistematis yang terstruktur. Berikut merupakan metode atau pendekatan yang diambil untuk membantu proses pengembangan aplikasi ini.



Gambar 2.1 Alur Metodologi Pengembangan Aplikasi

2.1.1. Studi Literatur

Melakukan eksplorasi serta pembelajaran yang cukup mendalam terhadap topik-topik yang terkait dengan proyek ini. Beberapa hal tersebut dapat mencakup topik-topik seperti *computer vision*, *convolutional neural network*, serta berbagai teknologi-teknologi lainnya yang diperlukan dalam mengembangkan aplikasi ini.

2.1.2. Perancangan Arsitektur

Melakukan perancangan arsitektur sistem kategorisasi gambar otomatis yang terdiri dari komponen perangkat lunak serta alur atau *workflow* proses kategorisasi gambar.

2.1.3. Pengumpulan Dataset

Pengumpulan dataset yang relevan dan berkualitas dilakukan dengan mencari dataset dari CIT sendiri, dengan juga mencari di berbagai sumber terbuka yang terpercaya seperti Hugging Face, Kaggle, GitHub, dan sumber-sumber lainnya. Pengumpulan data juga dapat dilakukan secara manual apabila diperlukan.

2.1.4. Pemilihan Model

Proses pemilihan model CNN ini melibatkan identifikasi dan evaluasi model-model yang populer dan banyak digunakan dalam bidang *image classification*. Penelitian dilakukan dengan meninjau publikasi-publikasi untuk memahami lebih lanjut mengenai model tersebut. Dengan melakukan pendekatan ini, penulis dapat lebih baik menentukan model terbaik yang sesuai dengan kebutuhan spesifik sistem kategorisasi gambar otomatis yang dikembangkan.

2.1.5. Penelitian Model

Metode ini mencakup pra-pemrosesan data, ekstraksi fitur gambar, pelatihan model, *fine-tuning* model, proses kategorisasi gambar, dan validasi hasil dengan menggunakan metrik evaluasi yang relevan.

2.1.6. Analisis

Setelah tahap penelitian model, akan dilakukan analisis terhadap hasil kinerja model berdasarkan berbagai konfigurasi yang telah diterapkan pada model untuk mengetahui bagaimana pengaruhnya terhadap performa dari model. Apabila kinerja model dianggap kurang memuaskan, maka tahap penelitian model dapat diulang kembali hingga didapatkan hasil yang mencapai kriteria yang ditentukan.

2.1.7. Pengujian

Apabila model telah mencapai kriteria yang ditentukan, akan dilakukan pengujian terhadap implementasi dari program pada proses *sorting* foto-foto acara CIT. Metode ini juga diperlukan adanya proses pemantauan terhadap proses *input* dan *output* dari data dan hasil pengklasifikasian.

2.2. Glosarium

2.2.1. *Artificial Intelligence*


Artificial Intelligence (AI) atau kecerdasan buatan merupakan sebuah bidang yang menyatukan *computer science* dan penggunaan *dataset* yang sesuai untuk menyelesaikan masalah tertentu. AI juga mencakup sub-bidang *machine learning* dan *deep learning*, yang sering disebutkan bersamaan dengan kecerdasan buatan. Keduanya ini terdiri dari algoritma AI yang berupaya untuk menciptakan sistem yang mahir dalam membuat prediksi atau klasifikasi berdasarkan data *input* (IBM, 2024).

2.2.2. *Computer Vision*

Computer vision adalah bidang ilmu komputer yang memiliki fokus untuk memungkinkan komputer mengidentifikasi dan memahami objek dan manusia dalam gambar dan video. *Computer vision* berupaya mereplikasi cara manusia melihat dan cara manusia memahami apa yang mereka lihat (Microsoft, 2024). Salah satu aplikasi dari *computer vision* adalah *image classification*, yang merupakan suatu tugas di mana algoritma komputer menganalisis dan memberikan label atau kategori pada gambar *input*.

2.2.3. *Convolutional Neural Network*

Convolutional Neural Network (CNN) merupakan kategori model *machine learning* yang termasuk dalam tipe *deep learning* yang sangat banyak digunakan dalam pengenalan dan pengolahan gambar. CNN mengadopsi pendekatan yang lebih efisien dalam mengekstrak fitur-fitur yang terdapat dalam gambar *input*. Melalui lapisan konvolusi, model dapat menggeser filter pada gambar dan mengenali setiap karakteristik dan pola yang ada pada fitur-fitur tersebut. Setelah dilakukan konvolusi akan dilakukan operasi *pooling* untuk mengurangi dimensi spasial data. Pada lapisan *fully connected* algoritma CNN melakukan perhitungan lebih lanjut yang bertujuan untuk melakukan klasifikasi (Dharmadi, 2018).



Gambar 2.2 Arsitektur CNN

2.2.3.1. Lapisan Konvolusi

Lapisan konvolusi merupakan lapisan mendasar yang melakukan mayoritas komputasi matematika yang dikenal dengan nama konvolusi pada gambar *input*. Konvolusi merupakan cara untuk menggabungkan nilai yang ada pada piksel gambar dengan sebuah *filter* atau *kernel* yang bertujuan untuk mengekstrak fitur atau sebuah pola tertentu pada gambar.

2.2.3.2. Lapisan *Pooling*

Bagian ini merupakan lapisan setelah lapisan konvolusi yang bertujuan untuk mereduksi dimensi data input. Hal ini biasanya dicapai dengan cara *downsampling*, yaitu mengurangi jumlah titik data dalam *input*, yang berarti mengurangi jumlah parameter atau piksel yang terdapat pada gambar. *Downsampling* secara signifikan mengurangi jumlah keseluruhan parameter dan komputasi sehingga meningkatkan efisiensi, memperkuat kemampuan generalisasi model, serta mengurangi potensi *overfitting*. Cara kerja dari lapisan *pooling* ini sangat mirip dengan lapisan konvolusi, yaitu dengan menggunakan sebuah *filter* yang bergeser di atas peta fitur yang dihasilkan oleh lapisan konvolusi. Namun yang menjadi pembeda adalah jika konvolusi melakukan operasi *dot product* antara filter dan bagian gambar, maka lapisan *pooling* ini melakukan operasi lain seperti mengambil nilai maksimum (*max pooling*) atau rata-rata dari bagian gambar (*average pooling*), hasil dari operasi ini kemudian disusun dan menjadi volume baru, yang menjadi *output* dari lapisan *pooling*.

2.2.3.3. Lapisan *Fully Connected*

Lapisan ini merupakan lapisan terakhir dari CNN yang berfungsi untuk mengklasifikasikan gambar berdasarkan fitur yang diekstraksi pada

lapisan sebelumnya. Istilah *fully connected* artinya setiap neuron pada satu lapisan terhubung dengan setiap neuron pada lapisan berikutnya. Lapisan ini mengintegrasikan berbagai fitur yang diekstraksi di lapisan-lapisan sebelumnya dan memetakannya ke kelas atau hasil tertentu. Setiap *input* dari lapisan sebelumnya terhubung ke setiap unit aktivasi di lapisan ini, memungkinkan CNN untuk secara bersamaan mempertimbangkan semua fitur saat membuat keputusan klasifikasi akhir.

2.2.4. Residual Network (ResNet)


ResNet adalah arsitektur *deep neural network* yang sangat berpengaruh dalam bidang *computer vision*, khususnya dalam tugas klasifikasi gambar. ResNet diperkenalkan oleh Kaiming He *et al.* dalam makalahnya yang berjudul “Deep Residual Learning for Image Recognition” pada tahun 2015. Inovasi utama ResNet terletak pada penggunaan *residual blocks*, yang memungkinkan pelatihan *neural network* yang sangat dalam/*deep* (ratusan atau bahkan ribuan lapisan) dengan memitigasi masalah *vanishing gradient* yang muncul akibat pendalaman jaringan/*network*. Secara umum, semakin dalam jaringan, semakin besar jumlah informasi yang dapat diperoleh dan semakin kuat pula karakteristiknya. Namun, eksperimen menunjukkan bahwa seiring bertambahnya kedalaman jaringan, dampak pengoptimalan menurun dan keakuratan data pengujian dan data pelatihan menurun. ResNet mengatasi masalah ini dengan memperkenalkan *skip connection* untuk membuat lapisan tertentu dari *neural network* melewati koneksi neuron di lapisan berikutnya dan menghubungkannya di lapisan alternatif, sehingga melemahkan hubungan kuat antara setiap lapisan (Xing Du *et al.*, 2023).

Arsitektur ResNet biasanya terdiri dari beberapa tahapan, masing-masing berisi beberapa *residual blocks*. Dalam setiap *residual block*, biasanya terdapat dua atau tiga lapisan konvolusional bersama dengan *shortcut connection*. Varian ResNet mencakup ResNet-18, ResNet-34, ResNet-50, ResNet-101, dan ResNet-152, dengan angka yang menunjukkan jumlah total lapisan (tidak termasuk lapisan *fully connected* di bagian akhir). ResNet telah mencapai kinerja tercanggih pada berbagai kumpulan dataset *benchmark* untuk tugas klasifikasi gambar, dan prinsip arsitekturalnya telah diadopsi dan diadaptasi secara luas dalam penelitian selanjutnya dan aplikasi praktis dalam *computer vision* dan seterusnya.

BAB III

DESAIN

3.1. Aplikasi Kategorisasi Gambar Otomatis



Gambar 3.1 Activity Diagram Aplikasi


Gambar 3.1 memperlihatkan alur proses secara *high-level* dari keseluruhan aplikasi kategorisasi otomatis tersebut. Diagram ini bertujuan agar pembaca dapat memahami dan memiliki gambaran secara garis besar mengenai proses-proses yang terjadi pada sistem.

3.1.1. Overview Desain

Sistem ini memiliki desain yang cukup *straightforward*. Pengguna akan mengunggah file zip yang berisi foto-foto yang ingin dikategorisasi ke dalam website aplikasi tersebut. File tersebut akan diambil oleh website lalu diproses di *backend*, kemudian file-file foto akan dikategorisasi/diklasifikasi oleh model AI yang telah dikembangkan. Setelah proses kategorisasi selesai, *backend* kemudian membagikan foto-foto yang telah dikategorisasi ke dalam beberapa folder berdasarkan kategori yang diberikan oleh AI. Semua folder tersebut kemudian dijadikan satu menjadi sebuah file zip, yang kemudian dikembalikan kepada website untuk dapat diunduh oleh user.


3.1.2. User Interface (UI)

User Interface (UI) merupakan aspek yang penting dalam desain aplikasi. UI yang baik mempermudah pengguna dalam menggunakan aplikasi dan juga menciptakan pengalaman yang memuaskan. Di dalam pengembangan dari UI aplikasi, beberapa teknologi dan framework pendukung akan digunakan untuk memudahkan pengembangan UI, seperti Vuejs.



Gambar 3.2 *Prototype* Desain UI: Home

Gambar 3.2. menunjukkan tampilan *Home* atau tampilan utama dari aplikasi. Ada tombol yang mencolok di tengah website yang bertuliskan “Select File” yang memungkinkan pengguna untuk mengunggah file yang diinginkan dalam format zip.



Gambar 3.3 *Prototype* Desain UI: setelah mengunggah file

Gambar 3.3. menunjukkan tampilan setelah pengguna berhasil mengunggah file. Ada tombol yang memungkinkan pengguna untuk mengganti file yang diinginkan, atau menghapusnya. Kemudian, ada tombol “process” yang berfungsi untuk memulai proses kategorisasi foto-foto di dalam file zip yang telah diberikan pengguna. Setelah proses kategorisasi selesai, maka akan dikembalikan file zip yang berisi folder-folder foto hasil kategorisasi yang dapat diunduh oleh pengguna.

3.2. Sistem AI

Model AI yang akan digunakan merupakan model *pre-trained*, yang berarti modelnya telah dilatih sebelumnya pada kumpulan dataset yang besar sebelum kemudian disesuaikan dan diaplikasikan ke proyek ini. Daripada melatih model dari awal, pengetahuan yang diperoleh selama pelatihan model yang telah dilatih sebelumnya dapat dimanfaatkan. Hal ini membuat proses pelatihan menjadi lebih efisien dan ukuran dataset yang digunakan tidak perlu terlalu besar.

3.2.1. Model

Model CNN yang akan digunakan pada proyek ini adalah model ResNet. Model ResNet dipilih dibandingkan model CNN yang lain seperti AlexNet, VGG, dan Inception karena ResNet cenderung lebih efisien dalam jumlah parameter namun tetap mencapai tingkat akurasi yang tinggi. ResNet memiliki kemampuan untuk mempelajari fitur tingkat tinggi dan rendah secara efektif. Penggunaan *skip connection* dalam ResNet memungkinkan jaringan untuk melewati lapisan tertentu

jika lapisan tersebut tidak memberikan kontribusi yang signifikan terhadap tugas pembelajaran, sehingga memungkinkan adaptasi yang lebih baik terhadap kompleksitas data dan menangkap detail yang sangat tinggi. *Skip connection* dalam ResNet juga memungkinkan jaringan untuk fokus mempelajari *residual mapping*, yang dapat menghasilkan konvergensi yang lebih cepat dan generalisasi yang lebih baik, terutama dalam skenario dengan data pelatihan terbatas (Sivaram, 2021).

3.2.2. Dataset

Dataset yang digunakan pada sistem ini adalah kumpulan foto-foto yang akan dibagi menjadi beberapa kelompok klasifikasi. Setiap kelompok akan memiliki folder masing-masing, dan nama dari folder akan menjadi label dari foto-foto di dalam kelompok tersebut. Dataset yang akan digunakan berasal dari CIT dan juga sumber data lain yang bersifat *open source* apabila diperlukan. Dataset yang diperoleh dari sumber *open source* berfungsi untuk menambah jumlah data latih apabila jumlah data dari CIT dianggap belum mencukupi. Kemudian, karena model yang akan digunakan merupakan model yang bersifat *pre-trained*, maka ukuran dataset tidak perlu terlalu besar. Banyaknya data berjumlah sekitar seribu per kelompok klasifikasi karena berdasarkan proyek berbeda dengan model yang sama yang pernah dikerjakan sebelumnya, dataset dengan ukuran tersebut mampu membuat model mencapai tingkat akurasi yang tinggi. Dataset akan dibagi ke dalam rasio 80:20, yaitu 80% untuk data latih dan 20% untuk data uji. Kemudian, 20% dari data latih akan dijadikan data validasi.

3.2.3. Kelompok Klasifikasi Model

Kelompok-kelompok klasifikasi disesuaikan dengan acara-acara yang biasanya diadakan oleh CIT. Contohnya, dalam acara CIT Mini Olympics (CITMO), ada beberapa cabang olahraga yang dilombakan, seperti basket, voli, tenis meja, dan bulu tangkis. Maka, foto-foto dokumentasi dari acara CITMO akan dibagi menjadi beberapa kelompok berdasarkan cabang-cabang olahraga tersebut. Pemilihan kelompok klasifikasi ditentukan berdasarkan atribut-atribut unik yang dapat ditemukan dalam acara CIT. Kelompok-kelompok klasifikasi tersebut yaitu:

1. Audience/Mass/Crowd
2. Badminton
3. Basket
4. Catur

5. Tenis Meja
6. Voli
7. Diskusi/Gathering
8. Donor Darah
9. Foto Bersama
10. Group Shot
11. Two Shot
12. Portrait
13. Landscape
14. Object
15. Pameran
16. Penyerahan Plakat/Sertifikat/Piala
17. Podium
18. Presentasi
19. Talkshow

3.2.4. Pengembangan Model

Model ResNet yang dipilih akan diuji terlebih dahulu performanya dengan suatu dataset tertentu. Selanjutnya, akan dilakukan *fine-tuning* untuk menyesuaikan model tersebut dengan dataset yang akan digunakan pada proyek ini. *Fine-tuning* memungkinkan model untuk menyesuaikan fitur-fitur yang dipelajarinya dengan tugas dalam proyek ini secara spesifik serta mencegah overfitting dengan perkembangan yang berdasarkan pengetahuan umum yang diperoleh selama pelatihan awal. Proses ini juga melibatkan *hyperparameter tuning*, yaitu penyempurnaan konfigurasi-konfigurasi di luar model, seperti *learning rate*, *batch size*, dan *epoch*. *Hyperparameter tuning* adalah langkah penting dalam proses pengembangan model, yang memengaruhi kemampuan model untuk belajar dan menggeneralisasi secara efektif. Pemilihan dan pengoptimalan *hyperparameter* yang cermat berkontribusi pada peningkatan performa model dan meningkatkan keberhasilan pembelajaran mesin secara keseluruhan.


Setelah melakukan *fine-tuning*, model akan dievaluasi menggunakan data uji untuk menentukan apakah model bekerja dengan performa yang baik dan memiliki akurasi yang cukup tinggi. Metrik evaluasi yang akan digunakan adalah *accuracy*, *precision*, *recall*, *F1 score*, dan *confusion matrix analysis*. Apabila hasil evaluasi kurang

memuaskan, maka proses *fine-tuning* dapat diulang agar mendapatkan hasil performa yang diinginkan. Secara keseluruhan, siklus perkembangan model ini merupakan proses iteratif, di mana penyesuaian dan pengujian dilakukan berulang kali hingga diperoleh hasil yang memenuhi kriteria yang diinginkan.

BAB IV

HASIL DAN PEMBAHASAN

4.1. *Data Preprocessing* (Pra-pemrosesan Data)



Gambar 4.1 Data Perwakilan dari Masing-Masing Kategori (Dari Kiri ke Kanan dan Atas ke Bawah: Audience/Mass/Crowd, Badminton, Basket, Catur, Diskusi/Gathering, Donor Darah, Foto Bersama, Group Shot, Landscape, Object, Pameran, Penyerahan Plakat/Sertifikat/Piala, Podium, Portrait, Presentasi, Talkshow, Tennis Meja, Two Shot, Voli)

Dataset bersumber dari bank foto departemen CR (Communications and Relations) CIT dan juga sumber yang bersifat *open-source*. Karena kelompok klasifikasi berjumlah 19, maka jumlah data berkisar pada 19 ribu. Langkah-langkah dalam tahap *data preprocessing* ini adalah sebagai berikut:

1. Pengunduhan dataset dari bank foto CR dan sumber *open-source*.
2. Membersihkan dataset dari data-data yang kotor.

3. Penyortiran dataset ke dalam beberapa folder berdasarkan kategori-kategori klasifikasi yang telah ditentukan.
4. Melakukan *downscaling* resolusi terhadap dataset foto dari CR agar ukuran file menjadi lebih kecil dan lebih mudah untuk diproses dalam pelatihan model.
5. Apabila masih ada sisa data setelah memenuhi kuota seribu per kategori klasifikasi, sisa data akan disimpan sebagai dataset cadangan.

4.2. Proses Pelatihan Model

4.2.1. Pemuatan Dataset

```
data = ImageDataLoaders.from_folder(path, train='train', valid='valid',
                                   item_tfms=Resize(460),
                                   batch_tfms=[*aug_transforms(size=224),
                                   Normalize.from_stats(*imagenet_stats)],
                                   valid_pct=0.2,
                                   num_workers=4)
```

Gambar 4.2 Blok Kode untuk Memuat Dataset

Pertama, dataset dalam folder-folder dimuat ke dalam *dataloader* dari Fastai. Objek *DataLoaders* adalah konstruksi Fastai yang menangani pemuatan dan pemrosesan data selama pelatihan dan validasi. Semua gambar untuk kategori yang berbeda berada di sub folder terpisah sehingga *dataloader* Fastai secara otomatis akan menganggap kelas dari data sebagai nama sub folder tersebut. 20% dari data latih akan dijadikan data validasi.

Semua gambar dataset akan ditransformasi ukurannya menjadi 460 pixel dengan tetap mempertahankan *aspect ratio* dari gambar. Kemudian, akan diterapkan serangkaian transformasi augmentasi yang mencakup *cropping*, *flipping*, *rotation*, dan lainnya secara acak, dan semuanya akan diubah ukurannya menjadi 224x224 pixel. Hal ini dilakukan untuk membantu meningkatkan *robustness* model dengan memaparkannya kepada berbagai versi gambar pelatihan yang diubah-ubah. Setelah itu, akan dilakukan normalisasi terhadap dataset gambar menggunakan nilai rata-rata dan deviasi standar dari kumpulan data ImageNet.

4.2.2. Setup Model

```
learn = vision_learner(data, models.resnet18, metrics=[accuracy],
model_dir = Path('../working'), path = Path("."))
```

Gambar 4.3 Blok Kode untuk *Setup* Model


Kode tersebut membuat objek *Learner* yang siap dilatih menggunakan arsitektur ResNet-18 yang memanfaatkan *transfer learning* terhadap dataset, mengevaluasi kinerja berdasarkan akurasi, dan menyimpan *progress* model dalam folder tertentu, di mana pada kasus ini nama foldernya adalah “working.”

4.2.3. Pelatihan Awal

```
learn.lr_find()
learn.recorder.plot_lr_find()
```

Gambar 4.4 Blok Kode untuk Memperkirakan *Learning Rate* Optimal

Sebelum pelatihan model benar-benar dimulai, akan dilakukan pencarian *learning rate* optimal terlebih dahulu menggunakan fungsi “lr_find()” dari Fastai. Fungsi ini digunakan untuk memperkirakan *learning rate* yang baik untuk melatih model ini. Fungsi ini akan melakukan uji rentang *learning rate*, yang membantu mengidentifikasi *learning rate* yang optimal dengan memberikan representasi grafik *loss* sebagai fungsi dari *learning rate*. Cara kerja dari fungsi ini adalah model akan diuji selama beberapa *epoch*, dimulai dengan *learning rate* yang sangat rendah dan meningkatkannya secara eksponensial pada setiap iterasi. Proses ini berlanjut hingga *learning rate*-nya mencapai nilai yang sangat tinggi atau *loss*-nya mulai menyimpang. Selama pengujian ini, hasil *loss* pada setiap *learning rate* akan disimpan. Setelah pengujian selesai, fungsi ini akan memplot grafik hubungan antara *loss* dan *learning rate* yang digunakan. Grafik ini membantu memvisualisasikan bagaimana nilai *loss* berubah dengan *learning rate* yang berbeda.



Gambar 4.5 Grafik *Loss* sebagai Fungsi dari *Learning Rate*

Berdasarkan grafik yang telah ditampilkan pada Gambar 4.5, terlihat bahwa *valley* atau lembah dari grafik dimulai dari titik yang terletak saat memasuki nilai *learning rate* 10^{-3} , dan nilai *loss* terkecil terdapat pada nilai *learning rate* yang mendekati 10^{-1} . Oleh karena itu, akan diambil rentang *learning rate* 10^{-3} hingga 10^{-1} untuk melatih model ini.


```
lr1 = 1e-3  
lr2 = 1e-1  
learn.fit_one_cycle(40,slice(lr1,lr2))
```

Gambar 4.6 Blok Kode untuk Melatih Model

Model kemudian dilatih menggunakan metode *One Cycle Learning Rate* (OneCycleLR) *Policy*, yang melatih model dengan *learning rate* yang bervariasi. Metode ini meningkatkan *learning rate* secara bertahap dari suatu nilai awal ke suatu nilai maksimum yang ditentukan dan kemudian kembali lagi dari nilai maksimum tersebut ke *learning rate* yang sangat mendekati nilai *learning rate* awal. Di akhir pelatihan, *learning rate*-nya sering kali semakin menurun bahkan hingga di bawah nilai awal untuk lebih menyempurnakan parameter dari model.


Pada dasarnya, OneCycleLR merupakan penerapan dari apa yang disebut sebagai *cyclic learning rates* (CLR). CLR berdampak pada proses pelatihan model yang dikenal sebagai *superconvergence* (superkonvergensi), di mana *neural network* dapat dilatih jauh lebih cepat dibandingkan dengan metode pelatihan standar (Smith & Topin, 2018). Secara optimal, *learning rate* harus ditetapkan ke nilai yang menyebabkan *network* untuk hanya mulai menyimpang pada puncaknya. Setelah itu, sisa pelatihan selanjutnya akan dilakukan dengan *learning rate* yang dikurangi secara bertahap, sehingga model dapat mencapai titik minimal pada permukaan *cost*. CLR bekerja dengan baik dalam praktiknya karena menggabungkan *learning rate* tercepat untuk penemuan makro wilayah minimum sebenarnya pada permukaan *cost* dengan penemuan mikro titik optimal pada wilayah tersebut saat *learning rate* diturunkan secara bertahap (Bilogur, 2019).

4.2.4. Hasil Pelatihan Awal




Gambar 4.7 Grafik *Accuracy per Epoch*

Berdasarkan grafik pada Gambar 4.7 setelah melakukan pelatihan model, dapat dilihat bahwa secara keseluruhan, model menunjukkan kenaikan akurasi secara bertahap sepanjang seluruh *epoch*. Pada tahap awal pelatihan, model menghasilkan akurasi yang mendekati 80%, namun kemudian menurun hingga titik terendahnya di 49% pada *epoch* 6. Tahap awal hingga pertengahan pelatihan (*epoch* 0 hingga 19) secara keseluruhan mengalami fluktuasi akurasi, yang kemudian akhirnya diikuti dengan tren kenaikan akurasi yang cukup konsisten hingga tahap akhir pelatihan. Hal ini berarti bahwa model menunjukkan tanda-tanda konvergensi mulai dari tahap pertengahan hingga akhir. Pada akhir pelatihan, akurasi dari model adalah 87,3%.



Gambar 4.8 Grafik *Train Loss per Epoch*



Gambar 4.9 Grafik *Train Loss dan Validation Loss per Epoch*

Grafik pada Gambar 4.8 dan Gambar 4.9 menunjukkan tren *train loss* naik selama beberapa *epoch* yang kemudian terus menurun secara konsisten, sedangkan *validation loss* mengalami fluktuasi yang cukup signifikan di tahap pertengahan pelatihan. Pada periode awal, *validation loss* menunjukkan penurunan yang stabil walaupun mengalami sedikit kenaikan hingga *epoch* 8. Namun, kemudian terjadi beberapa lonjakan *validation loss*, terutama pada 20 hingga 22, yang merupakan lonjakan signifikan tertinggi dengan nilai 149,54. Lonjakan signifikan ini menunjukkan *overfitting*, di mana model ini memiliki performa yang baik terhadap data pelatihan tetapi gagal dalam menggeneralisasi data validasi. Hal ini kemungkinan besar terjadi karena *learning rate* pada OneCycleLR sedang berada pada puncaknya, yang menyebabkan pembaruan parameter yang besar dan akhirnya mengakibatkan

ketidakstabilan. Setelah lonjakan signifikan ini, *validation loss* menunjukkan tren menurun yang mencerminkan peningkatan generalisasi dari model yang juga ditunjukkan oleh akurasi model yang meningkat. Hal ini berarti bahwa meskipun ada fluktuasi pada tahap awal hingga pertengahan, model ini pada akhirnya dapat menggeneralisasi data pelatihan dan validasi dengan baik.

4.2.5. Fine-Tuning Model


```
learn.unfreeze()  
learn.fit_one_cycle(20,slice(1e-4,1e-3))
```

Gambar 4.10 Blok Kode untuk *Fine-Tuning* Model dengan *Unfreezing* Lapisan yang Dibekukan


Selanjutnya, akan dilakukan *fine-tuning* pada model dengan melakukan *unfreezing* lapisan yang dibekukan pada model terlebih dahulu. Pada tahap pelatihan sebelumnya, semua lapisan konvolusi (Conv2d) pada *network* dibekukan secara otomatis sehingga lapisan-lapisan tersebut tidak dapat dilatih. Hal ini dilakukan untuk mempertahankan kemampuan ekstraksi fitur yang telah dilatih sebelumnya pada dataset besar seperti ImageNet sehingga menghindari kebutuhan untuk mempelajari kembali fitur-fitur dasar dari awal, seperti tepi, tekstur, dan bentuk dari gambar. Selain itu, hal ini juga secara signifikan mengurangi jumlah parameter yang perlu diperbarui, sehingga mempercepat proses pelatihan dan mengurangi konsumsi sumber daya. *Unfreezing* kemudian dilakukan agar semua lapisan yang dibekukan sebelumnya dapat dilatih. Dengan melakukan *unfreezing* dan melatih semua lapisan, model dapat menyesuaikan bobot *pre-trained* secara lebih halus ke dataset spesifik yang digunakan sehingga model dapat menghasilkan performa yang lebih baik.

Model kemudian akan dilatih kembali dengan OneCycleLR selama 20 *epoch* dengan rentang *learning rate* 10^{-4} hingga 10^{-3} . Rentang yang diambil lebih rendah karena dalam melakukan *fine-tuning*, *learning rate* yang lebih kecil membantu melakukan penyesuaian menyeluruh pada semua bobot tanpa mengubahnya secara drastis. Hal ini memastikan pembaruan bobot yang lebih stabil dan terkontrol, mencegah model menyimpang atau melampaui bobot optimal. Rentang *learning rate* yang lebih rendah membantu model konvergen secara lebih efektif pada proses *fine-tuning* dengan menetap pada nilai minimum lokal yang lebih optimal.


4.2.6. Hasil *Fine-Tuning*




Gambar 4.11 Grafik Perbandingan *Accuracy per Epoch* sebelum dan setelah *Fine-Tuning*



Gambar 4.12 Grafik *Train Loss* dan *Validation Loss per Epoch* setelah *Fine-Tuning*



Gambar 4.13 Grafik Perbandingan *Train Loss per Epoch* sebelum dan setelah *Fine-Tuning*



Gambar 4.14 Grafik Perbandingan *Validation Loss per Epoch* sebelum dan setelah *Fine-Tuning*

Berdasarkan Gambar 4.11, grafik akurasi selama proses *fine-tuning* model memiliki tren yang kurang lebih sama dengan proses pelatihan sebelumnya, namun dengan peningkatan yang lebih cepat dan hasil akhir yang lebih tinggi, yaitu 93,3%. Pada Gambar 4.13, grafik *train loss* menunjukkan tren penurunan yang lebih stabil dan konsisten dibandingkan sebelumnya. Gambar 4.14 menunjukkan grafik *validation loss* yang sedikit berfluktuasi pada tahap awal hingga pertengahan proses *fine-tuning*, namun akhirnya menjadi cukup stabil dan menurun hingga tahap akhir. Model tidak mengalami lonjakan *validation loss* yang ekstrem seperti pada proses pelatihan sebelumnya. Secara keseluruhan, *fine-tuning* model menunjukkan stabilitas dan

generalisasi yang lebih baik, serta akurasi yang lebih tinggi dan *loss* yang lebih baik dan konsisten dibandingkan dengan tahap pelatihan awal. Hal ini menunjukkan bahwa performa model mengalami peningkatan yang cukup signifikan pada proses *fine-tuning* dengan melakukan *unfreezing* lapisan-lapisan pada model dan mengambil rentang *learning rate* yang lebih kecil.

4.3. Pengujian Model dengan Data Uji dan Analisis Performa

```
test_path = Path('test_data')
test_dl = loaded_learner.dls.test_dl(get_image_files(test_path),
with_labels=True)
results = loaded_learner.validate(dl=test_dl)
```

Gambar 4.15 Blok Kode untuk Menguji Model dengan Data Uji

Tahap selanjutnya adalah pengujian model menggunakan data uji. Blok kode di atas akan membuat DataLoader pengujian dari data uji. Kemudian, model yang telah dimuat akan dievaluasi pada dataset pengujian. Variabel “results” akan berisi metrik hasil komputasi, yaitu *validation loss* dan akurasi terhadap dataset pengujian.


Metric	Score
Accuracy	92,53%
Average Precision	92,81%
Average Recall	92,77%
Average F1 Score	92,76%

Gambar 4.16 Performa Model setelah Pengujian

Berdasarkan Gambar 4.16, akurasi model dari hasil pengujian adalah 92,5%, yang sangat mendekati akurasi model dari hasil pelatihan. Tingkat akurasi yang tinggi ini menunjukkan bahwa model tersebut secara umum efektif dalam membedakan berbagai kategori gambar. *Average precision* model adalah 92,8%, yang mencerminkan kemampuan model untuk mengidentifikasi dengan benar contoh positif dari setiap kelas sambil meminimalkan jumlah *false positive*. Skor presisi tinggi ini menunjukkan bahwa ketika model memprediksi suatu gambar masuk dalam kelas tertentu, model tersebut hampir selalu benar. *Average recall* sebesar 92,77%, yang menunjukkan kemampuan model untuk mengidentifikasi semua contoh yang relevan dari setiap kelas. Skor *recall* yang tinggi ini menunjukkan bahwa model tersebut mahir dalam menangkap sebagian besar *true positive* dan memiliki tingkat *false positive* yang rendah. *Average F1 score*

sebesar 92,76%, yang merupakan *harmonic mean* dari *precision* dan *recall*. Skor ini memberikan metrik tunggal yang menyeimbangkan *precision* dan *recall*, sehingga memberikan gambaran komprehensif mengenai performa model. Skor F1 yang tinggi menegaskan bahwa model tersebut menjaga keseimbangan yang baik antara *precision* dan *recall*, menangani *false positive* dan *false negative* secara efektif.

Nilai akurasi, *precision*, *recall*, dan skor F1 yang tinggi secara keseluruhan menunjukkan bahwa model tersebut memiliki performa yang sangat baik di berbagai metrik. Secara keseluruhan, hal ini menunjukkan bahwa model tersebut kuat dan dapat diandalkan, sehingga cocok untuk aplikasi praktis yang memerlukan klasifikasi gambar yang akurat.



Gambar 4.17 *Confusion Matrix* dari Hasil Pengujian Model

Berdasarkan *confusion matrix* pada Gambar 4.17, dapat dilihat bahwa mayoritas jumlah prediksi terletak pada diagonal matriks, yang menunjukkan bahwa model memiliki kinerja yang baik dalam memprediksi kelas dengan benar. Namun, kita dapat melihat bahwa ada beberapa kategori yang menunjukkan kesalahan klasifikasi yang lebih tinggi


dibandingkan kategori-kategori lain. Tiga pasangan kategori yang mengalami kesalahan klasifikasi terbanyak adalah:

1. Two Shot dengan Group Shot: model salah mengklasifikasikan "Two Shot" menjadi "Group Shot" sebanyak 20 kali dan sebaliknya sebanyak 16 kali, yang menjadikan mereka pasangan yang *most confused*. Hal ini menunjukkan bahwa kedua kelas ini memiliki kesamaan visual yang signifikan sehingga model cukup kesulitan membedakannya.
2. Portrait dengan Two Shot: model salah mengklasifikasikan "Portrait" menjadi "Two Shot" sebanyak 18 kali dan sebaliknya sebanyak 7 kali.
3. Diskusi/Gathering dengan Group Shot: model salah mengklasifikasikan "Diskusi/Gathering" menjadi "Group Shot" sebanyak 9 kali dan sebaliknya sebanyak 8 kali.

Selain itu, ada beberapa yang lain yang juga mengalami kesalahan klasifikasi dengan frekuensi yang lebih moderat, yaitu:

1. "Two Shot" menjadi "Donor Darah" sebanyak 5 kali dan sebaliknya.
2. "Diskusi/Gathering" menjadi "Two Shot" sebanyak 5 kali dan sebaliknya sebanyak 4 kali.
3. "Group Shot" menjadi "Audience/Mass/Crowd" sebanyak 5 kali.
4. "Penyerahan Plakat/Sertifikat/Piala" menjadi "Two Shot" sebanyak 5 kali.
5. "Object" menjadi "Landscape" sebanyak 5 kali.
6. "Object" menjadi "Portrait" sebanyak 5 kali.

Kesalahan klasifikasi yang dapat diamati dalam *confusion matrix* terutama berasal dari kemiripan visual dan tumpang tindih yang inheren di antara kategori-kategori tertentu. Misalnya, kategori seperti "two shot" dan "group shot" melibatkan lebih dari satu orang dalam berbagai pengaturan, sehingga sering menimbulkan kebingungan di antara mereka. Demikian pula, kategori seperti "diskusi-gathering" dan "group shot" dapat tampak serupa secara visual karena kehadiran banyak orang dalam suasana diskusi. Selain itu, beberapa kesalahan klasifikasi mungkin disebabkan oleh variabilitas yang tidak mencukupi dalam kelas tertentu, sehingga menyulitkan model untuk membedakannya. Mengatasi masalah ini melalui augmentasi data, penyeimbangan kelas, dan penyesuaian model lebih lanjut dapat membantu mengurangi kesalahan klasifikasi seperti ini dan meningkatkan performa model secara keseluruhan.



Gambar 4.18 Lima Prediksi yang Terbaik oleh Model



Gambar 4.19 Lima Prediksi yang Terburuk oleh Model

Gambar 4.18 menunjukkan 5 hasil prediksi terbaik oleh model pada saat tahap pengujian dengan loss yang bernilai nol untuk semua hasil prediksi, sedangkan Gambar 4.19 menunjukkan 5 hasil prediksi terburuk oleh model dengan nilai loss yang melebihi 500 untuk semua hasil prediksi.

4.3.1. Perbandingan Kinerja Model

Model	Metric	Score
ResNet18	Accuracy	92,53%
	Average Precision	92,81%
	Average Recall	92,77%
	Average F1 Score	92,76%
VGG11	Accuracy	87,62%
	Average Precision	87,85%
	Average Recall	88,29%
	Average F1 Score	87,96%
AlexNet	Accuracy	89,48%
	Average Precision	89,07%
	Average Recall	89,49%
	Average F1 Score	89,20%

Gambar 4.20 Perbandingan Kinerja ResNet dengan VGG dan AlexNet


Untuk membandingkan kinerja model ResNet18 yang digunakan, telah dilakukan penelitian menggunakan model VGG11 dan AlexNet. Gambar 4.20 menyajikan perbandingan kinerja dari ketiga model tersebut. ResNet18 menunjukkan kinerja terbaik di semua metrik dibandingkan dengan VGG11 dan AlexNet. Dengan akurasi, *average precision*, *average recall*, dan *average F1 score* tertinggi, ResNet18 terbukti menjadi model paling efektif untuk klasifikasi gambar dalam penelitian ini. Arsitekturnya yang dirancang untuk mengatasi masalah *vanishing gradient* dan memungkinkan *network* yang lebih dalam/*deep* kemungkinan besar berkontribusi pada performanya yang unggul.

4.4. Aplikasi


Aplikasi web dibangun dengan menggunakan *framework* Vuejs untuk *frontend* dan Flask untuk *backend*. Berikut merupakan alur proses penggunaan aplikasi ini:

1. Pengguna mengunggah file zip yang berisi foto-foto yang ingin dikategorisasi dengan menekan tombol "Select File."
2. File zip diambil oleh website lalu dikirimkan ke *backend*.
3. *Backend* memproses file zip, lalu masing-masing file foto akan diklasifikasi oleh model AI.


4. File-file foto dikategorisasi/diklasifikasi berdasarkan kategorinya oleh model AI.
5. *Backend* kemudian membagi-bagikan foto-foto yang telah dikategorisasi ke dalam beberapa folder berdasarkan hasil klasifikasi oleh model.
6. Semua folder tersebut kemudian dijadikan satu menjadi sebuah file zip.
7. File zip hasil klasifikasi dikembalikan kepada website.
8. Website membuat tautan pengunduhan file zip tersebut.
9. User mengunduh file zip hasil klasifikasi melalui tautan yang diberikan.



Gambar 4.21 Home Page Aplikasi Web



Gambar 4.22 Tampilan *Page* Setelah Mengunggah dan Memproses File Zip, kemudian File Zip Hasil Pemrosesan Diunduh



Gambar 4.23 File Zip Hasil Pengunduhan

BAB V

KESIMPULAN DAN SARAN

5.1. Kesimpulan

Penelitian ini menunjukkan pentingnya memanfaatkan model *pre-trained* dan teknik *fine-tuning* untuk meningkatkan kinerja dalam tugas klasifikasi gambar. Peningkatan yang diamati setelah *fine-tuning* menegaskan pentingnya penyesuaian *learning rate* dan strategi pelatihan berdasarkan hasil pelatihan awal. Pekerjaan di masa depan dapat berfokus pada mengatasi tantangan spesifik yang diidentifikasi dalam *confusion matrix*, mungkin melalui inkorporasi fitur yang lebih diskriminatif atau teknik augmentasi lanjutan untuk lebih menyempurnakan akurasi model.

Kesimpulannya, penelitian ini telah berhasil mencapai semua tujuan yang telah ditetapkan. Aplikasi kategorisasi gambar otomatis telah berhasil dikembangkan dengan tingkat keakuratan yang tinggi dengan menerapkan teknologi kecerdasan buatan menggunakan CNN. Model CNN yang digunakan telah terbukti efektif dan efisien dalam mengkategorikan gambar ke dalam berbagai kategori dengan tingkat akurasi yang tinggi, mencapai 92,5% terhadap dataset pengujian. Selain itu, aplikasi kategorisasi gambar yang dikembangkan dapat disesuaikan dengan kebutuhan spesifik dari CIT. Terakhir, model AI yang telah dibangun telah berhasil diintegrasikan dengan website aplikasi, memungkinkan penggunaan yang mudah dan praktis bagi pengguna. Dengan demikian, penelitian ini telah mencapai tujuan utamanya dalam mengembangkan aplikasi kategorisasi gambar otomatis yang handal dan dapat diimplementasikan dalam lingkungan nyata.

5.2. Saran

Penelitian ini telah menunjukkan hasil yang memuaskan dalam pengembangan aplikasi kategorisasi gambar otomatis menggunakan teknologi kecerdasan buatan. Namun, masih ada beberapa area yang dapat dikembangkan lebih lanjut untuk meningkatkan fungsionalitas dan kegunaan aplikasi ini. Pertama, penambahan fitur untuk mengidentifikasi dan menandai gambar berdasarkan tingkat kepentingan acara (*event importance*) dapat menjadi langkah signifikan. Fitur ini memungkinkan pengguna untuk tidak hanya mengkategorikan gambar, tetapi juga menilai pentingnya setiap gambar dalam konteks tertentu, seperti acara perusahaan atau kegiatan sosial, sehingga memberikan nilai tambah bagi pengguna yang membutuhkan analisis lebih mendalam.

Selain itu, pengembangan lebih lanjut dapat mencakup penambahan modul untuk analisis sentimen atau emosi dalam gambar. Dengan menggunakan teknik pemrosesan citra yang lebih canggih, aplikasi ini dapat mendeteksi ekspresi wajah atau suasana hati dari orang-orang dalam gambar, memberikan wawasan tambahan tentang dinamika acara yang tertangkap dalam gambar tersebut.

Terakhir, pengembangan antarmuka pengguna yang lebih intuitif dan ramah pengguna akan sangat bermanfaat. Dengan menyediakan pengalaman pengguna yang lebih baik, aplikasi ini dapat menarik lebih banyak pengguna dan memfasilitasi adopsi yang lebih luas dalam berbagai industri.

Secara keseluruhan, meskipun penelitian ini telah berhasil mencapai tujuannya, masih banyak peluang untuk pengembangan lebih lanjut yang dapat meningkatkan kemampuan dan aplikasi praktis dari sistem kategorisasi gambar ini.

DAFTAR PUSTAKA

- Ash, Doug. 2022. "Why Is Photography Important? Document, Self-Expression, Art, Love!" Doug Ash Photography. February 26, 2022. <https://dougashphotography.com/why-is-photography-important/>.
- Aqeel Anwar. 2019. "Difference between AlexNet, VGGNet, ResNet and Inception." Medium. Towards Data Science. June 7, 2019. <https://towardsdatascience.com/the-w3h-of-alexnet-vggnet-resnet-and-inception-7baaecccc96>.
- Awati, Rahul. 2022. "What Is Convolutional Neural Network? - Definition from WhatIs.com." SearchEnterpriseAI. September 2022. <https://www.techtarget.com/searchenterpriseai/definition/convolutional-neural-network>.
- Bab 2 landasan teori - kc.umn.ac.id. (n.d.-a). https://kc.umn.ac.id/id/eprint/16584/4/BAB_II.pdf
- Bab II tinjauan pustaka 2.1 Convolutional Neural Network (CNN). (n.d.-b). <http://repositori.unsil.ac.id/7652/6/6.%20BAB%20II.pdf>
- Bilogur, Aleksey. 2019. "One-Cycle Learning Rate Schedulers." Kaggle. <https://www.kaggle.com/code/residentmario/one-cycle-learning-rate-schedulers>.
- Dharmadi, R. (2018, April 23). "Mengenal Convolutional layer Dan pooling layer." Medium. <https://medium.com/nodeflux/mengenal-convolutional-layer-dan-pooling-layer-3c6f5c393ab2>
- Du, Xing, Yongfu Sun, Yupeng Song, Huifeng Sun, and Lei Yang. 2023. "A Comparative Study of Different CNN Models and Transfer Learning Effect for Underwater Object Classification in Side-Scan Sonar Images." Remote Sensing 15, no. 3 (January): 593. <https://doi.org/10.3390/rs15030593>.
- He, Kaiming, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. 2015. "Deep Residual Learning for Image Recognition." <https://arxiv.org/pdf/1512.03385.pdf>.
- Kien, Chau Tuan. 2022. "Skip Connection and Explanation of ResNet." Medium. October 8, 2022. <https://chautuankien.medium.com/skip-connection-and-explanation-of-resnet-afabe792346c>.

- Microsoft Azure. n.d. "What Is Computer Vision? | Microsoft Azure." Azure.microsoft.com. <https://azure.microsoft.com/en-us/resources/cloud-computing-dictionary/what-is-computer-vision#object-classification>.
- Smith, Leslie N. 2018. "A Disciplined Approach to Neural Network Hyper-Parameters: Part 1 -- Learning Rate, Batch Size, Momentum, and Weight Decay." ArXiv:1803.09820 [Cs, Stat], April (April). <https://arxiv.org/abs/1803.09820>.
- Smith, Leslie N., and Nicholay Topin. 2018. "Super-Convergence: Very Fast Training of Neural Networks Using Large Learning Rates." ArXiv:1708.07120 [Cs, Stat], May (May). <https://arxiv.org/abs/1708.07120>.
- T, Sivaram. 2021. "What Are Skip Connections in Deep Learning?" Analytics Vidhya. August 24, 2021. <https://www.analyticsvidhya.com/blog/2021/08/all-you-need-to-know-about-skip-connections/#h-why-skip-connections>.
- What is Artificial Intelligence (AI) ?*. IBM. (n.d.). <https://www.ibm.com/id-en/topics/artificial-intelligence>